TV_lesson-04. Конструирование законов распределения вероятностей составных ДСВ

Построение распределения вероятности для суммы, разности и произведения СВ:

- сумма очков при бросании двух, трех, ... кубиков;
- произведение очков при бросании двух кубиков.

Построение вероятностных распределений ДСВ для составных испытаний:

- биномиальное распределение,
- отрицательное биномиальное распределение,
- распределение Пуассона.

Смеси распределений. Пример испытания, приводящего к смеси вероятностных распределений.

Построение распределения вероятности для результатов операций со случайными величинами

- Со СВ, как и с обычными величинами можно оперировать складывать/вычитать, уножать/делить, ...
- отличие только в том, что в результате операции получается также СВ со своим распределением вероятностей ее значений.



Сумма, разность и произведение двух ДСВ

Рассмотрим две СВ X и Y, для которых известны их законы распределения, т.е. их функции вероятностей:

$$egin{aligned} p_X(): x_i & o p_i, \ p_i &\geq 0, \ i = 1..n; \sum_{i=1}^n p_i = 1. \ p_Y(): y_j & o q_j, \ q_j &\geq 0, \ j = 1..m; \sum_{j=1}^m q_j = 1 \end{aligned}$$

Какой закон распределения будет у СВ Z=X+Y , Z=X-Y , $Z=X\cdot Y$?

Рассмотрим случай независимых ДСВ.

Примеры постановок задач

▼ Пример "Продолжение знакомства с девушкой".

Ура, мы познакомились с симпатичной девушкой и договорились с нею встретиться в субботу в парке на том же самом месте! Мы уже опытные ловеласы и понимаем, что успех - т.е. возможность дальнейшего общения и продолжение серьезных отношений зависит от

• в каком настроении придет девушка - в хорошем (X = 1), в нейтральном (X = 0.5) или не в настроении (X = 0);

• в каком состоянии будет парень (в том числе и в финансовом состоянии): в хорошем и финансово и физически (Y = 2), в хорошем физически, но не очень финансово (Y = 1), в плачевном состоянии (Y = 0).

Практика показывает, что шансы на продолжение отношений хорошие:

- при знакомстве с состоятельными девушками, если $X+Y \geq 2.5$;
- с просто милыми девушками, если $X \cdot Y \geq 1$.

Определите шансы парня на продолжение отношений

- а) с состоятельной красавицей;
- б) с просто милашкой;

если известны законы распределения для (будем считать) независимых СВ X и Y:

x_i	0	0.5	1
p_i	0.2	0.5	0.3
y_i	0	1	2
p_i	N 1	0.5	0.4



ВОПРОС. Как можно описать содержательно событие $X+Y \geq 2.5$?

▼ Пример. Анализ резюме претендентов на вакантную должность

Рассмотрим две независимые CB X и Y. Например, кол-во проанализированных за день резюме на вакантную должность двумя разными работниками. Так как каждый из них, будем считать, работает независимо от другого (возможно, что они работают удаленно и не знают друг друга), то и результаты их работы не связаны никак.

Также их результат может зависеть от очереди резюме претендентов. Они просто берут из очереди первую необслуженную заявку и ее рассматривают. Если в очереди заявки завершаются, то тогда и результат их работы будет зависеть от количества заявок в очереди на этот день. Как вырожденный случай такой зависимости - это когда нет вакансий, а значит и рассматривать нечего. Учет возможной ограниченности очереди - это мостик к рассмотрению смеси распределений. А пока будем считать очередь неограниченной. Т.е. кол-во рассмотренных резюме ограничивается только производительностью работников.

Ясно, что заранее спрогнозировать какое кол-во резюме i-й работник сможет сегодня проанализировать сложно, так как резюме могут сильно отличаться друг от друга объемом и составом ключевых слов, с помощью которых описываются скиллы. Поэтому X = "кол-во проанализированных резюме за день работником №1" и Y = "кол-во проанализированных резюме за день работником №2" можно считать случайными величинами.

Пусть мы набрали достаточно данных, чтобы утверждать, что полученные эмпирические распределения вероятностей для СВ X и Y достаточно устойчивы.

x_i	0	1	2	3	4	5		
p_i	0	0	0.2	0.3	0.3	0.2		
y_i	0	1	2	3	4	5	6	7
Di	Ω	0.1	0.1	0.2	0.2	0.1	0.1	0.1

Нас будут интересовать ответы на следующие вопросы:

- что можно сказать о суммарном кол-ве проанализированных резюме за день (распределение суммы)?
- можно ли сказать, что какой-то из работников лучше работает или нет (распределение разности)?



ВОПРОС. Как можно сформулировать словесно событие $A = (X = 4) \cdot (Y = 5)$?

▼ Пример "Процесс подключения клиента к системе интернет-платежей".

Рассмотрим две независимые СВ:

- Х = "кол-во дней, затраченных на проверку заявки (MRM), которая завершилась успешно";
- Y = "кол-во дней на подключение клиента после успешной проверки заявки";

Нас будет интересовать общее кол-во дней на обработку заявки клиента, которое завершилось успешным его подключением.



ВОПРОС. Как можно сформулировать словесно событие $A = (X + Y \le 5)$?

ullet Построение функции вероятностей для $Z=X\ op\ Y$, где X,Y - НЕзависимые СВ.

Рассмотрим процесс построения функции вероятностей для совместного распределения двух независиымх СВ X,Y на примере "Продолжение знакомства с девушкой".

В это примере нам известны законы распределения для (будем считать) независимых СВ X (настроение девушки) и Y (состояние парня):

Функция вероятности для СВ Х

$$x_i$$
 0 0.5 1 | \sum

Функция вероятности для СВ Ү

$$y_j$$
 0 1 2 \sum q_j 0.1 0.5 0.4 \prod 1.0

Построим закон распределения вероятности для пары (X, Y). Для этого нам надо рассмотреть все возможные пары значений этих величин (x_i, y_j) и найти соответствующие вероятности их появления одновременно в одном испытании.

Для этого подготовим такую таблицу:

$x_i \setminus y_j$	0	1	2	p_i
0				0.2
0.5				0.5
1				0.3
q_{j}	0.1	0.5	0.4	1.0

Чтобы ее заполнить, нам надо найти для каждой пары значений (x_i, y_j) вероятность ее появления. Это все равно, что найти вероятность произведения событий:

$$p_{i,j} = p(x_i, y_j) = p((X = x_i) \cdot (Y = y_j))$$

Так как мы считаем данные CB независимыми, то независимы и события $(X=x_i), (Y=y_j)$, а это означает, что

$$p_{i,j} = p((X=x_i)\cdot (Y=y_j)) = p(X=x_i)\cdot p(Y=y_j) = p_i\cdot q_j$$

Используя последнее равенство, мы легко заполним таблицу, задающую закон распределения вероятности для пары Х,У:

$x_i \setminus y_j$	0	1	2	p_i
0	0.02	0.1	0.08	0.2
0.5	0.05	0.25	0.2	0.5
1	0.03	0.15	0.12	0.3
q_{j}	0.1	0.5	0.4	1.0

Зная закон совместного распределения СВ X, Y, мы можем теперь легко найти закон распределения для результата любой бинарной операции с этими СВ.



ВОПРОС. Чему равна вероятность того, что X+Y=3 ?

ullet Построение функции вероятностей для Z=X+Y, где X,Y - независимые CB

Воспользуемся построенным законом распределения для векторной СВ (X,Y) и найдем закон распределения для СВ

•
$$Z = X + Y$$

Для этого воспользуемся той же таблицей для наглядности и в каждую ячейку таблицы впишем получающееся значение $z_{i,j} = x_i + y_j$:

$x_i \setminus y_j$	0	1	2
0	0 (0.02)	1 (0.1)	2 (0.08)
0.5	0.5 (0.05)	1.5 (0.25)	2.5 (0.2)
1	1 (0.03)	2 (0.15)	3 (0.12)

В скобках мы оставили вероятности появления данных пар значений Х,Ү.

Теперь мы можем выписать функцию вероятности для Z=X+Y. Для этого надо просто просуммировать вероятности всех случаев, когда $Z=z_k$. Например,

$$p(Z=1) = p((X=0) \cdot (Y=1) + (X=1) \cdot (Y=0)) = p((X=0) \cdot (Y=1)) + p((X=1) \cdot (Y=0)) = 0.1 + 0.03 = 0.13$$

Получаем такое распределение:



ВОПРОС. Чему равна вероятность успешного продолжения знакомства с состоятельными девушками, если

$$p("$$
 УСПЕХ " $)=p(X+Y\geq 2.5)$

ullet Построение функции вероятностей для $Z=X\cdot Y$, где X,Y - независимые СВ

Воспользуемся построенным законом распределения для векторной СВ (X,Y) и найдем закон распределения для СВ

•
$$Z = X \cdot Y$$

Аналогично примеру со сложением впишем в таблицу совместного распределения значения СВ $Z = X \cdot Y$:

$x_i ackslash y_j$	0	1	2	
0	0 (0.02)	0 (0.1)	0 (0.08)	
0.5	0 (0.05)	0.5 (0.25)	1 (0.2)	
1	0 (0.03)	1.0 (0.15)	2 (0.12)	
p(Z =	1) = p	o((X=0)	0.5) · (Y	$(Y=2) + (X=1) \cdot (Y=1)) = p((X=0.5) \cdot (Y=2)) + p((X=1) \cdot (Y=1))$
= 0.2 -	+0.15	= 0.35		

Получаем такое распределение:



ВОПРОС. Чему равна вероятность успешного продолжения знакомства с просто милыми девушками, если

$$p$$
(" УСПЕХ ") = $p(X \cdot Y \ge 1)$

ullet Построение функции вероятностей для Z = XopY, где X,Y - зависимые СВ

здесь алгоритм тот же, за исключением того, что теперь мы не можем посчитать вероятность $p((X=x_i)\cdot (Y=y_j))$ как произведение вероятностей. Теперь эту вероятность надо оценивать с помощью наблюдений и вычисления относительной частоты появления данной пары значений вместе.

Также можно использовать формулу с условной вероятностью $p(Y=y_j/X=x_i)$, если она известна или может быть легко найдена:

$$p(A \cdot B) = p(A) \cdot p(B/A)$$

для нашего случая она будет выглядеть так:

$$p((X = x_i) \cdot (Y = y_j)) = p(X = x_i) \cdot p(Y = y_j/X = x_i))$$

▼ ПРИМЕР. В списке резюме на вакантную должность имеется 3 подробно расписанных резюме и 5 кратких.

Какова вероятность того, что второй рецензент получит краткое резюме, если 1-й рецензент получил подробное резюме на анализ. Здесь

- событие А = "1-й рецензент получил подробное резюме на анализ"
- событие В = "2-й рецензент получил краткое резюме на анализ".

$$p(B/A) = \frac{5}{5+2} = \frac{5}{7}$$

$$p(A \cdot B) = p(A) \cdot p(B/A) = \frac{3}{8} \cdot \frac{5}{7} = \frac{15}{56}$$



ВОПРОС. Какова вероятность того, что второй рецензент получит краткое резюме, если неизвестно, какое резюме получил на анализ 1-й рецензент?

Построение вероятностных распределений ДСВ для составных испытаний

▼ Биномиальное распределение

Данное распределение получается, если мы проводим серию из N испытаний Бернулли. Обозначим через $X_j, j=1..N$ - С.В., каждая из которых подчиняется закону Бернулли с параметром p и принимающие значение 1 или 0 в зависимости от того наступил Успех или НеУспех в одном испытании.

Вероятность успеха в каждом испытании, p одна и та же и и не зависит от результатов предыдущих испытаний.

Рассмотрим случайную величину Y, которая показывает количество успехов в серии из N испытаний. Мы можем считать, что C.B. Y получается при сложении C.B. $X_j, j=1..N$, каждая из которых подчиняется закону Бернулли с параметром p:

$$Y = X_1 + X_2 + \ldots + X_N.$$

Закон распределения для X_j результата j-го испытания Бернулли:

Тогда мы можем утверждать, что:

• вероятность того, что во всех испытаниях был успех равна

$$p(Y = N) = p((X_1 = 1) \cdot (X_2 = 1) \cdot ... \cdot (X_N = 1)) = p^N;$$

• вероятность того, что во всех испытаниях был Неуспех равна

$$p(Y=0) = (1-p)^N;$$

• вероятность того, что в серии из N испытаний успех наступил только один раз равна

$$p(Y = 1) = N \cdot p^1 \cdot (1 - p)^{N-1}$$
.

Но чтобы построить биномиальный закон распределения, нам надо определить значение функции вероятности для всех возможных исходов, а их ровно N+1:

Чтобы найти вероятность события, что "успех наступил ровно k раз в серии из N испытаний", надо:

• найти вероятность того, что успех произошел в каких-то (пусть первых) k испытаниях:

$$p(X_1=1,\ldots,X_k=1,X_{k+1}=0,\ldots,X_N=0)=p^k\cdot (1-p)^{N-k}$$

ullet найти количество комбинаций k испытаний, в которых мог произойти успех в общем числе испытаний N:

$$C_N^k = \frac{N!}{(N-k)! \cdot k!}$$

Фактически, мы решаем задачу - сколькими способами мы можем k неразличимых шаров (успехов) разместить в N перенумерованных лунках (испытаниях).

Просуммировав все эти несовместные исходы в серии испытаний, мы получим формулу k успехов в серии из n испытаний Бернулли с вероятностью успеха p:

$$p_n(k) = C_n^k \cdot p^k \cdot (1-p)^{n-k}.$$

Это и есть **функция вероятности для биномиального распределения** для серии из N испытаний с вероятностью успеха p.

Про такую С.В. говорят, что она подчиняется биномиальному закону распределения с параметрами n и p:

$$X \in Bin(n,p)$$

▼ Почему биномиальный?

Биномиальным данное распределение называется потому, что здесь фактически зайдествован бином Ньютона:

$$1 = ((1-p)+p)^n = C_n^0 \cdot p^0 \cdot (1-p)^n + C_n^1 \cdot p^1 \cdot (1-p)^{n-1} + \ldots + C_n^k \cdot p^k \cdot (1-p)^{n-k} + \ldots + C_n^n \cdot p^n \cdot (1-p)^0$$

например, для серии из двух испытаний имеем:

$$1 = p_2(0) + p_2(1) + p_2(2) = ((1-p)+p)^2 = (1-p)^2 + 2p(1-p) + p^2$$

Иллюстрация Биномиального распределения при N=10. Доска Гальтона



ЗАДАНИЕ

ВОПРОС: Является ли пара противоположных событий (A, \bar{A}) полной группой?

ВОПРОС: Какое событие является противоположным для события D = "транзачит" (из примера о подключении клиентов)?

ВОПРОС: Образуют ли события A = "монета упала орлом вверх", B = "монета упала решкой вверх" полную группу событий (из примера о бросании монеты)?

▼ Нормальный закон распределения - как предел биномиального распределения

Рассмотрим иллюстрацию биномиального закона распределения:

https://www.edumedia-sciences.com/ru/media/905

А теперь рассмотрим СВ "Сумма очков в серии бросания кубика". Давайте рассмотрим иллюстрацию того, как меняется закон распределения суммы очков в серии из 2-х, 3-х и более бросаний кости:

Иллюстрация распределения вероятности для суммы очков в серии бросания кости

▼ Закон Пуассона - как аппроксимация биномиального распределения

Рассмотрим СВ Y = "Кол-во заявок на обслуживание за час". Мы уже отмечали ранее, что данную величину можно рассматривать как серию испытаний Бернулли с вероятностью успеха р (УСПЕХ = "вызов в эту минуту").

Значение данной CB мы можем найти просто просуммировав значения CB Xi, i=1..60 полученные при ежеминутном испытании Бернулли:

$$Y = \sum_{i=1}^{60} X_i$$

Давайте рассмотрим иллюстрацию того, как меняется закон распределения кол-ва вызовов в серии из 10, 20 и более минут, с использованием биномиального закона и сраним его с законом Пуассона:

$$p_{\lambda}(k) = \frac{(\lambda)^k \cdot e^{-\lambda}}{k!}$$

```
где \lambda = n \cdot p = 0.04 \cdot n.
```

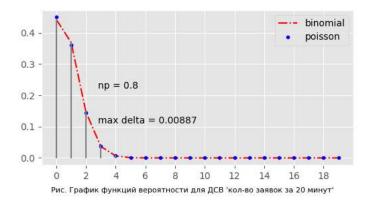
```
# импорт библиотеки для работы с массивами, последовательностями и для построения графиков import numpy as np import pandas as pd import matplotlib.pyplot as plt
plt.style.use('ggplot')
```

используем готовые функции для законов распределения дискретных СВ из библиотеки scipy https://docs.scipy.org/doc/scipy/reference/stats.html#discrete-distributions

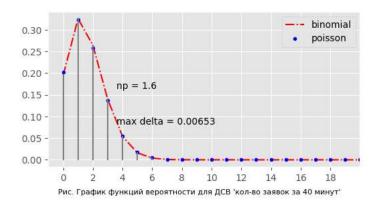
```
# Загрузим библиотеку с вероятностными законами распределения
from scipy.stats import binom, poisson
def create_bin_prob(n, p):
    def bin_prob(k):
        return binom.pmf(k, n, p)
    return bin_prob
{\tt def\ create\_poisson\_prob(n,\ p):}
    lamda = n * p
    def poisson prob(k):
        return poisson.pmf(k, lamda)
    return poisson_prob
def drawing(n, p=0.04, xmax=20):
    plt.figure(figsize=(6, 3))
    # совместим график функции вероятности биномиального закона с законом Пуассона
    bin_prob = create_bin_prob(n, p)
    poisson prob = create poisson prob(n, p)
    ki = np.array(range(n))
    bin_pi = bin_prob(ki)
    poisson\_pi = poisson\_prob(ki)
    plt.plot(ki, bin_pi, '-.', c='red', label="binomial")
plt.plot(ki, poisson_pi, '.', c='blue', label="poisson")
    for i in range(len(ki)):
        plt.plot([ki[i], ki[i]], [0, bin_pi[i]], c='grey')
    plt.text(n*p + 2, max(bin_pi) / 2, s=f"np = {n * p}")
    max_delta = np.round(np.max(np.abs(poisson_pi - bin_pi)), 5)
    plt.text(n*p + 2, max(bin\_pi) / 4, s=f"max delta = \{max\_delta\}")
    plt.suptitle(f"Рис. График функций вероятности для ДСВ 'кол-во заявок за {n} минут'", у=0, fontsize=8)
    plt.xlim(-1, 20)
    plt.xticks(np.arange(0, xmax, 2))
```

plt.show()

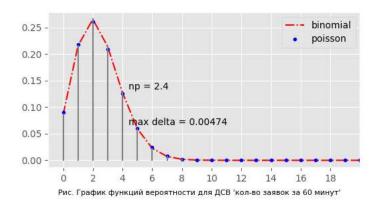
drawing(n=20)



drawing(n=40)



drawing(n=60)



drawing(n=60*6, xmax=30)



▼ Отрицательный биномиальный закон

Это закон распределения кол-ва испытаний в серии испытаний Бернулли до появления "Успеха". Если нам известна вероятность успеха в одном испытании, то можно легко построить данный закон:

$$x_i$$
 1 2 3 4 ...

Пример "Бросание монеты до появления решки"

Пусть наш эксперимент состоит в подбрасывании монеты до тех пор, пока не выпадет решка. СВ X - количество таких бросаний. Таблично мы не сможем задать распределение вероятности из-за бесконечного числа возможных значений СВ:

$$x_i$$
 1 2 3 4 ... $p(x_i)$ 0.5 0.25 0.125 0.0625 ...

(считаем монету идеальной). Но можем задать закон распределения вероятности теперь с помощью отображения:

$$p(X=k)=2^{-k}, \ k=1,2,3,\dots$$

Можно убедиться, что данный закон отвечает условию нормировки:

$$\sum_{k=-1}^{\infty} p(X=k) = 0.5 * (1 + 0.5 + 0.25 + 0.125 + \dots) = 0.5 * \frac{1}{1 - 0.5} = 1$$



ЗАДАЧА.

Пусть С.В. X подчиняется отрицательному биномиальному распределению с вероятностью успеха p=0.3.

Найдите вероятность события, что с.в. X примет значение больше 2:

$$p(X > 2) = ?$$

Что более вероятней, что CB окажется больше 2-х или противоположное событие ($X \leq 2$)?

Смеси распределений. Пример испытания, приводящего к смеси вероятностных распределений.

Пример формирования смеси распределений

Рассмотрим формирование смеси распределений на примере задачи "Анализ резюме претендентов на вакантную должность".

Пусть у нас есть один рецензент и два сорта резюме "легкие" и "тяжелые" (см. пример выше). Рассмотрим функции вероятности для СВ X = "Кол-во рассмотренных резюме за день" в двух случаях:

- случай А = "на рецензию поступают только подробные (тяжелые) резюме"
- случай В = "на рецензию поступают только краткие (легкие) резюме".

Пусть мы накопили достаточно кол-во наблюдений и выяснили, что "тяжелые" резюме рецензент анализирует и пишет рецензию в среднем за два часа (4 за день), а легкие за 1 час (8 - за день). Воспользуемся законом Пуассона, чтобы описать распределение СВ Х Функция вероятности для $p_A(x)$

$$p_A(k) = \frac{4^k \cdot e^{-4}}{k!}$$

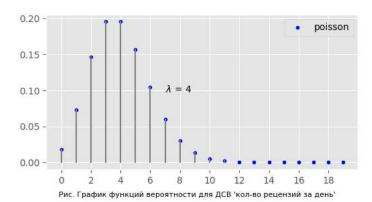
Функция вероятности $p_B(x)$

$$p_B(k)=rac{8^k\cdot e^{-8}}{k!}$$

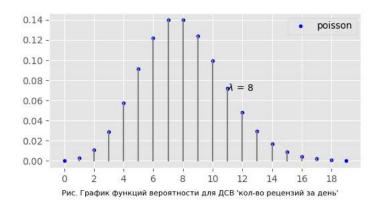
```
def poisson_drawing(lamda, xmax=20):
    plt.figure(figsize=(6, 3))
    ki = np.arange(xmax)
    poisson_pi = poisson.pmf(ki, lamda)
    plt.plot(ki, poisson_pi, '.', c='blue', label="poisson")
    for i in range(len(ki)):
        plt.plot([ki[i], ki[i]], [0, poisson_pi[i]], c='grey')
    plt.text(lamda + 3, max(poisson_pi) / 2, s=f"$\lambda$ = {lamda}")
    plt.suptitle(f"Рис. График функций вероятности для ДСВ 'кол-во рецензий за день'", y=0, fontsize=8)
```

```
plt.xlim(-1, xmax)
plt.xticks(np.arange(0, xmax, 2))
plt.legend()
plt.show()
```

poisson_drawing(lamda=4, xmax=20)



poisson_drawing(lamda=8, xmax=20)



Нас будут интересовать ответы на следующие вопросы:

- А как описать распределение СВ X в более общем случае, когда будут попадаться и легкие и тяжелые, если нам известны доля тяжелых и доля легких резюме?
- можно ли использовать имеющиеся распределения для описания более общего случая?

Давайте смоделируем ситуацию случайного выбора заявки из очереди. Пусть у нас имеется СВ Ү, которая принимает два значения:

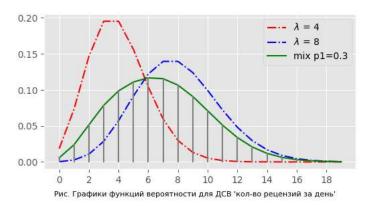
- 0 если заявка оказалась тяжелой;
- 1 если заявка оказалась легкой

Пусть мы знаем, что доля легких заявок составляет 0.7. Тогда имеем следующее распределение Бернулли:

Наша гипотеза, что в итоге мы получим смесь этих двух распределений в пропорции, задаваемой этим распределением Бернулли

```
def mix_drawing(lamda1, lamda2, p1, xmax=20):
    plt.figure(figsize=(6, 3))
    ki = np.arange(xmax)
    p1_i = poisson.pmf(ki, lamda1)
    p2_i = poisson.pmf(ki, lamda2)
    pmix_i = p1 * p1_i + (1 - p1) * p2_i
    plt.plot(ki, p1_i, '--', c='red', label=f"$\lambda$ = {lamda1}")
    plt.plot(ki, p2_i, '--', c='blue', label=f"$\lambda$ = {lamda2}")
    plt.plot(ki, pmix_i, '-', c='green', label=f"mix p1={p1}")
    for i in range(len(ki)):
        plt.plot([ki[i], ki[i]], [0, pmix_i[i]], c='grey')
    plt.suptitle(f"Рис. Графики функций вероятности для ДСВ 'кол-во рецензий за день'", y=0, fontsize=8)
    plt.xlim(-1, xmax)
    plt.tzticks(np.arange(0, xmax, 2))
    plt.legend()
    plt.show()
```

mix_drawing(lamda1=4, lamda2=8, p1=0.3, xmax=20)



В следующих уроках мы смоделируем эту ситуацию с использованием распределения времени рассмотрения рецензии и посмотрим насколько полученное в эксперименте распределение совпадает с нашей теоретической смесью.

Резюме

- в результате арфиметических операций со СВ получается СВ;
- чтобы найти закон распределения для результата оперирования со СВ X и Y нужно построить закон их совместного распределения или распределения векторной СВ (X, Y):

$$p(x_i, y_j)$$

• если СВ X и Y независимы, то построить закон их совместного распределения легко, просто перемножая соответствующщие вероятности:

$$p(x_i, y_i) = p(X = x_i) \cdot p(Y = y_i)$$

- биномиальный закон описывает количество успехов в серии из п испытаний и определяется двумя параметрами п и р;
- СВ, распределенная по биномиальному законц получается в результате суммирования СВ результатов испытаний Бернулли;
- ullet биномиальный закон в пределе (при $n o\infty$) дает закон Пуассона (для ДСВ) и нормальный закон распределения (для НСВ);
- на практике мы имеем чаще всего смесь известных законов, описывающих поведение СВ.